무통신(off) 보상이 학습할수록 떨어지는 이유 — 진단

2026-10-07 · 배치 f2_ 학습 곡선 + 무통신 체크포인트(12M · 16M) 평가 12건 · 학습 없음 · 코드 feat/fig1-latent 74b5988

> **한 줄 결론** — '학습할수록'이 아니라 **선생님 흉내 손실이 꺼진 뒤(12.04M)**부터 떨어짐. 흉내가 켜진 동안은 오르고, 꺼지면 PPO 혼자서는 정책을 지키지 못함. 한 항을 얻으려고 다른 항을 버린 것이 아니라 도착 · 충돌 · 판정 벌점 · 나머지가 전부 나빠짐(3/3 시드). 통신 팔도 같은 시점부터 내려가나 폭이 작음.

1. 학습 곡선 — 언제 떨어지는가

- 흉내 보조손실은 갈래 시작(9.04M)에서 1 로 켜져 3M 결정에 걸쳐 0 이 됨 → 12.04M 부터 꺼짐
- 무통신 도착률: 흉내 켜진 끝 무렵 81.1 · 81.8 · 75.9 % → 끝 77.8 · 58.9 · 48.9 %. 시드 44 · 45 가 무너지고 43 은 버팀
- 같은 뿌리에서 다시 갈라 본 무통신(offb)은 시드 44 만 무너짐(77.5 · 58.6 · 70.9 %) → 무너지는지 여부가 시드 · 갈래마다 다름(운에 가까움)
- 통신도 12M 뒤로 내려감: 결정당 보상 0.928 · 0.831 · 0.742 → 0.880 · 0.635 · 0.612. 3/3 시드가 내려가나 폭이 작음
- 공통 뿌리(흉내가 3M 에 꺼진 뒤 9.04M 까지)는 평평했음. 흉내 없이 꾸준히 오른 구간은 어느 팔에도 없음 (통신 시드 43 · 44 는 꺼진 직후 1M 동안 조금 더 오른 뒤 내려감)

	공통 뿌리 6–9.04M		흉내 켜짐 11–12M		꺼진 직후 12–13M		끝 15–16M	
	평균	시드 43 · 44 · 45	평균	시드 43 · 44 · 45	평균	시드 43 · 44 · 45	평균	시드 43 · 44 · 45
무통신 off — 도착 %	**73.9**	76.2 · 75.1 · 70.3	**79.6**	81.1 · 81.8 · 75.9	**76.5**	82.3 · 75.8 · 71.3	**61.9**	77.8 · 58.9 · 48.9
무통신 off — 결정당 보상	**0.187**	0.232 · 0.183 · 0.145	**0.227**	0.212 · 0.297 · 0.170	**0.213**	0.305 · 0.235 · 0.100	**−0.008**	0.230 · 0.018 · −0.273
무통신 다시 갈래 offb — 도착 %	**73.9**	76.2 · 75.1 · 70.3	**77.0**	77.2 · 81.1 · 72.7	**74.4**	78.7 · 78.8 · 65.7	**69.0**	77.5 · 58.6 · 70.9
무통신 다시 갈래 offb — 결정당 보상	**0.187**	0.232 · 0.183 · 0.145	**0.203**	0.209 · 0.270 · 0.130	**0.180**	0.239 · 0.281 · 0.019	**0.081**	0.153 · −0.145 · 0.235
통신 comm — 도착 %	**73.9**	76.2 · 75.1 · 70.3	**87.5**	88.2 · 86.5 · 87.9	**88.4**	89.1 · 90.2 · 86.0	**82.5**	86.4 · 77.8 · 83.2
통신 comm — 결정당 보상	**0.187**	0.232 · 0.183 · 0.145	**0.770**	0.793 · 0.720 · 0.798	**0.833**	0.928 · 0.831 · 0.742	**0.709**	0.880 · 0.635 · 0.612

학습 중 기록(샘플 행동)의 구간 평균. 괄호 없는 작은 글씨 = 시드 43 · 44 · 45.

2. 12M 과 16M 체크포인트를 같은 조건으로 평가 — 무엇이 나빠졌는가

	시드 43	시드 44	시드 45	
	12M 체크포인트 → 16M(끝) 체크포인트			
도착 % (샘플 행동)	78.2 → 74.5	73.4 → 45.6	60.9 → 43.8	주 평가와 같은 방식
도착 % (평균 행동 = 잡음 없음)	83.6 → 78.4	79.8 → 49.8	69.8 → 42.9	정책 자체가 나빠졌는지
1000결정당 보상 합계	+294 → +178	+186 → −14	+91 → −197	
· 도착 보상 (+150/건)	+119 → +103	+113 → +88	+106 → +82	
· 충돌 벌점 (−300/건)	−50 → −59	−62 → −149	−101 → −148	
· 역할 판정 벌점 (−20/건)	−34 → −40	−36 → −45	−36 → −42	
· 나머지 (전진·시간·연료·근접·위험)	+259 → +174	+171 → +92	+122 → −88	
1000결정당 충돌 건수	0.167 → 0.195	0.208 → 0.496	0.336 → 0.495	
1000결정당 좌현 변침 벌점(F1) 건수	0.796 → 1.112	0.847 → 0.984	0.858 → 1.112	
침로 명령 크기 평균 ° (샘플)	10.8 → 13.3	11.1 → 12.4	10.9 → 16.1	목표 방향에서 벗어난 각
침로 명령 크기 평균 ° (평균 행동)	3.5 → 9.4	5.2 → 4.4	3.1 → 14.0	
뱃머리 돌린 총량 °/도착 (평균 행동)	95 → 156	95 → 128	84 → 160	

- 보상의 네 항이 전부 나빠짐(3/3 시드). 가장 크게 준 항 = 시드 43 나머지(−86) · 시드 44 충돌(−86) · 시드 45 나머지(−210). 1000결정당 충돌 0.167 · 0.208 · 0.336 → 0.195 · 0.496 · 0.495
- 잡음이 커진 탓이 아님: 행동 잡음 σ(침로) 는 0.137 → 0.141 · 0.136 → 0.147 · 0.145 → 0.160 로 거의 그대로. 잡음을 뺀 평균 행동으로 몰아도 도착 83.6 · 79.8 · 69.8 → 78.4 · 49.8 · 42.9 % → 정책 자체가 나빠짐
- 덜 돌아서가 아님: 뱃머리 돌린 총량이 3/3 시드에서 늘었음(평균 행동 95 · 95 · 84 → 156 · 128 · 160°). 침로 명령 크기는 샘플 행동 3/3 증가, 평균 행동 2/3 증가(시드 44 는 줄었음). 좌현 변침 벌점(F1)도 3/3 늘어남 → 더 돌면서 더 부딪힘
- '나머지' 항 안에서 어느 것(전진·연료·근접·위험)이 줄었는지는 따로 나누지 않았음

평가 = 256 env · burn-in 2400 · 평가 창 2000결정 · 평가 시드 999. 창이 짧아 도착률 값 자체는 주 평가(10000결정)보다 낮게 나옴 → 12M 과 16M 의 비교로만 읽을 것.

3. 확인된 것 · 아닌 것

- 보상 순위가 뒤집힌 것은 아님: 같은 보상으로 잰 에피소드 보상이 무통신 선생님 649 > 안 피하는 배 260 > 학습 무통신 3 (10-06 주 평가). 좋은 행동이 보상도 높음
- 정보가 모자란 것도 아님: 같은 56 m 정보만 쓰는 선생님이 도착 90.6 % · 충돌 8.6 %
- 따라서 남는 것은 '학습이 보상을 못 따라감'임. 흉내가 꺼진 뒤 PPO 갱신만으로는 정책이 유지되지 않음 (무통신 갈래 6개 중 3개가 끝 구간 도착 60 % 아래로 무너짐: off 44 · 45, offb 44)

---

4. 왜 PPO 가 못 따라가는가 (가설 — 아직 측정 안 함)

- 가설 A: 수익의 분산이 큼. 가치 정규화 통계가 평균 +1.4 · 표준편차 129.8(시드 44 공통 뿌리) → 평균 −11.0 · 표준편차 140.6(시드 44 끝). 충돌 −300 · 도착 +150 · 판정 −20 이 드물게 크게 들어와 학습 신호가 잡음에 묻힘
- 가설 B: 무통신 배가 볼 수 없는 것에 벌점이 붙음. 역할 판정과 위험 비용은 300 m 에서 시작하는데 무통신 배는 56 m 만 봄 → 관측으로 설명 안 되는 보상. 통신 팔이 덜 내려가는 것과 맞음
- 둘 다 '학습 신호가 약하다'는 같은 방향이고, 어느 쪽이 큰지는 모름

---

5. 설계 관점

- 현재 설계에서 무통신 보상 곡선의 모양 = 평평(공통 뿌리) → 상승(흉내 켜짐) → 하락(흉내 꺼짐). 우상향 곡선이 아님
- 오르는 구간이 흉내가 켜진 구간과 겹침. 흉내 몫과 PPO 몫을 나눠 재지는 않았음. 통신 팔의 상승도 같은 구간임(10-06 보고와 같음)
- 학습 없이 더 확인할 수 있는 것(약 30분, 평가만): 12M 체크포인트에서 critic 이 수익을 얼마나 설명하는지(설명 분산)를 무통신 · 통신으로 재어 가설 A · B 를 가름

자료: runs/2026-10-02_fig1/out/diag_offdrop/ (로그 12개) · 스크립트 runs/2026-10-02_fig1/report/diag/offdrop/ · 이 문서 report/make_report_offdrop.py