R0 무학습 재평가 — 표본 행동 vs 평균 행동 (qb_ · qa_)

2026-10-27 · LICS 서버 · 코드 feat/fig1-latent 071487b · 스펙 2026-10-26-ref-port-sigma-trunk-design.md §2(기록용 · 관문 아님) · 학습 없음 · 이미 있는 체크포인트 18개(qb_ trunk 5 · off 4 · comm 4 · qa_ trunk 5) · 시드 43 하나 · 평가 256 env · 3000 결정 · burn-in 2400 · drain 3000 · 평가 시드 999(고정 장면 곡선과 같은 인자)

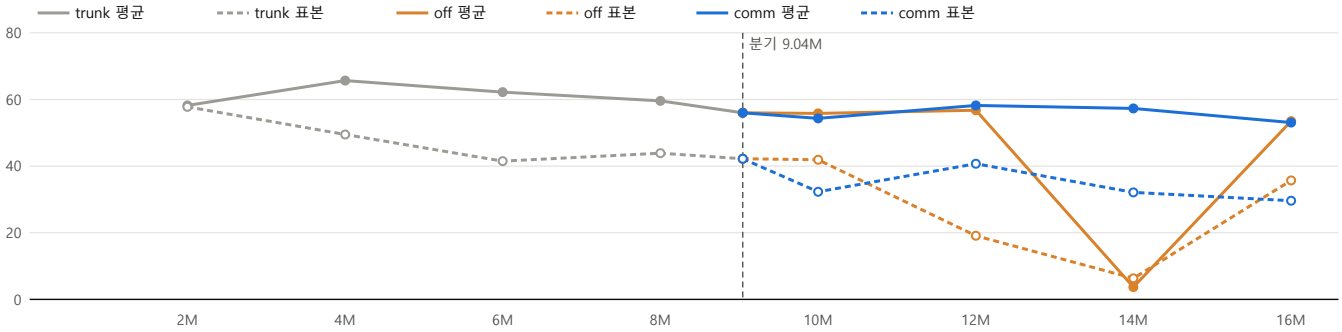
> **한 줄 결론** — 평균 행동(tanh(mean), 표본 잡음 없음)이 표본 행동보다 도착이 높은 체크포인트 **17/18**, 그 차가 10 pt 이상 **16/18**(+13.8 – +37.7 pt). 배끼리 충돌도 평균 행동이 낮은 체크포인트 17/18. 예외는 qb_ trunk 2M(+0.4 pt)과 qb_ off 14M(평균 행동도 도착 3.7 % 로 무너짐). trunk 3개(n_ · qb_ · qa_)의 9.04M 평균 행동 도착은 54.6 · 56.0 · 54.8 % 로 비슷함 — 표본 행동(28.8 · 42.2 · 36.3 %)만 벌어짐. qa_(ARPA@300) 평균 행동 도착은 4M 이 최고(71.0 %), 9.04M 54.8 %. qb_ off · comm 순서는 추정량에 따라 바뀜: 끝점(16M)은 표본 · 평균 모두 off 위, K 점 평균은 둘 다 comm 위(평균 행동 55.7 vs 42.5 %) — 이 차는 off 14M 하나에서 나옴(빼면 거의 같음). 시드 1개 · 기록용 → 원인 주장 · 팔 판정 안 함. R1(σ trunk 3팔)은 저자 승인 대기.

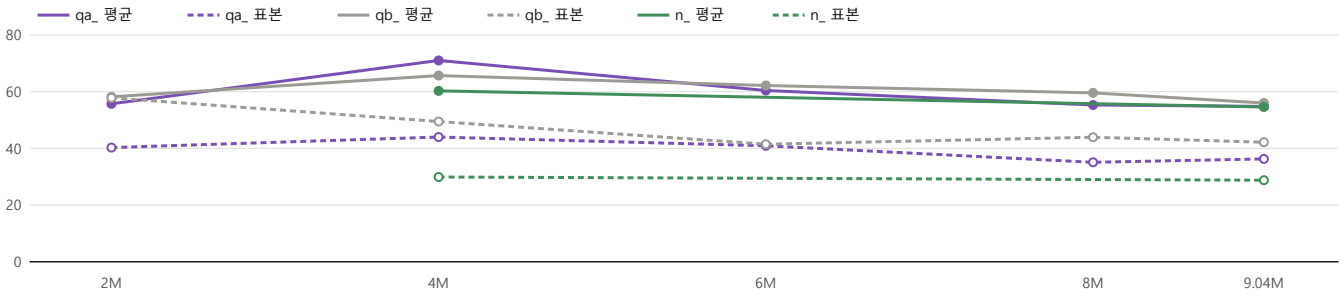
1. 체크포인트별 표본 / 평균 행동

런	체크포인트	σ 침로 °	도착 % 표본	도착 % 평균	평균 − 표본	배 충돌 % 표본 / 평균	벽 · 시간초과 % 평균	epReward 표본 / 평균	에피소드 수 표본 / 평균
qb_ trunk	2M	17.8	57.8	58.2	+0.4	42.0 / 41.8	0.0 · 0.0	−449 / −269	10758 / 10655
qb_ trunk	4M	18.7	49.5	65.7	**+16.2**	48.2 / 33.9	0.0 · 0.4	−517 / 230	9191 / 11508
qb_ trunk	6M	19.2	41.5	62.2	**+20.7**	55.5 / 37.4	0.0 · 0.4	−692 / 256	8348 / 11884
qb_ trunk	8M	20.1	43.9	59.6	**+15.7**	53.5 / 39.8	0.0 · 0.6	−742 / 115	8935 / 11843
qb_ trunk	9.04397M	20.6	42.2	56.0	**+13.8**	55.4 / 43.4	0.0 · 0.6	−721 / 24	9210 / 12024
qb_ off	10M	20.8	41.9	55.8	**+13.9**	56.0 / 43.7	0.0 · 0.4	−637 / 42	9648 / 12320
qb_ off	12M	21.2	19.1	56.8	**+37.7**	73.9 / 42.4	0.0 · 0.8	−1386 / 49	6863 / 10537
qb_ off	14M	21.4	6.3	3.7	−2.6	86.6 / 88.6	0.0 · 7.7	−1855 / −1630	5622 / 5470
qb_ off	16M	21.4	35.7	53.5	**+17.8**	60.6 / 45.7	0.0 · 0.8	−977 / −78	8560 / 11868
qb_ comm	10M	20.8	32.3	54.3	**+22.0**	63.3 / 44.9	0.0 · 0.8	−1200 / −21	7732 / 11275
qb_ comm	12M	21.3	40.7	58.2	**+17.5**	56.6 / 41.2	0.0 · 0.7	−791 / 57	8891 / 12038
qb_ comm	14M	21.7	32.1	57.3	**+25.2**	64.8 / 42.1	0.0 · 0.6	−932 / 108	8536 / 11958
qb_ comm	16M	22.0	29.6	53.1	**+23.5**	65.6 / 46.2	0.0 · 0.8	−1222 / −80	7567 / 11116
qa_ trunk	2M	47.2	40.3	55.7	**+15.4**	56.5 / 43.4	0.0 · 0.9	−951 / −374	8196 / 10352
qa_ trunk	4M	48.0	44.0	71.0	**+27.0**	50.7 / 26.4	0.0 · 2.6	−1207 / −177	6606 / 7832
qa_ trunk	6M	47.9	40.9	60.4	**+19.5**	51.6 / 35.8	0.9 · 2.8	−1045 / −74	6020 / 7241
qa_ trunk	8M	48.3	35.1	55.3	**+20.2**	51.8 / 37.7	0.4 · 6.6	−1130 / −68	4928 / 5953
qa_ trunk	9.04397M	48.7	36.3	54.8	**+18.5**	47.1 / 35.3	0.4 · 9.5	−1138 / −62	4391 / 5530
n_ trunk (10-13 D)	4M	47.9	29.9	60.3	**+30.4**	64.3 / 38.6	0.0 · 1.1	−1343 / 37	6874 / 10363
n_ trunk (10-13 D)	9.04397M	50.3	28.8	54.6	**+25.8**	66.2 / 44.8	0.0 · 0.6	−1296 / 79	7693 / 12535

- 표본 = 학습 정책 그대로(매 결정 가우시안 표본 → tanh), 평균 = 같은 정책의 tanh(mean)(`eval_mean.py`, ctr_actor 첫 반환값만 바꿈). 나머지 설정 · 장면 · 평가 시드 같음
- σ 침로 = `logstd_dump.py` 의 sigma_course = 120° × exp(행동 0번 logstd 의 전문가 5개 평균), tanh 전 근사값. qb_ 는 학습 때 logstd 초기 −2.0 이라 17.8–22.0°, qa_ 는 기본 초기값이라 47.2–48.7°
- qb_ 표본 값은 10-13 phase1 고정 장면 곡선(`curve_qb_*.txt`, 같은 인자)을 그대로 씀 — 값이 같음을 확인. qa_ 표본은 이번에 새로 잼
- 회색 줄 n_ = 10-13 단계 1 D(같은 인자) 값을 비교로 옮겨 적음. 이번에 다시 잰 것 아님
- epReward 는 모양 보상(shaped) 합 — 평균 행동이 대부분 양수로 바뀌나 판정 지표 아님

2. 그림 — 도착 % (실선 = 평균 행동, 점선 = 표본 행동)


trunk 평균
trunk 표본
off 평균
off 표본
comm 평균
comm 표본
분기 9.04M
80
60
40
20
0
2M
4M
6M
8M
10M
12M
14M
16M


qa_ 평균
qa_ 표본
qb_ 평균
qb_ 표본
n_ 평균
n_ 표본
80
60
40
20
0
2M
4M
6M
8M
9.04M

3. 스펙 §2 보고 항목

(a) 체크포인트별 평균 − 표본 격차

- 18개 중 양수 17 · 10 pt 이상 16. 런별 범위: qb_ trunk +0.4 – +20.7 · qb_ off −2.6 – +37.7 · qb_ comm +17.5 – +25.2 · qa_ trunk +15.4 – +27.0 pt
- qb_ trunk 2M 만 격차 ≈ 0(표본 57.8 · 평균 58.2 %). 4M 부터 격차가 생김. 표본 도착 57.8 → 49.5 → 41.5 → 43.9 → 42.2 %, 평균 행동 58.2 → 65.7 → 62.2 → 59.6 → 56.0 %
- 스펙 R1 처방 성공 기준 제안(격차 ≤ 10 pt)을 이 자료에 대 보면 9.04M 에서 n_ · qb_ · qa_ 모두 못 미침 — R1 은 이 격차를 줄이는지 보는 실험임

(b) trunk 9.04M 세 개 비교

trunk 9.04M	다른 점(같은 보상 · 시드 43)	σ 침로 °	도착 % 표본	도착 % 평균	평균 − 표본	배 충돌 % 평균
n_	ARPA@56 · 토글 없음	50.3	28.8	54.6	+25.8	44.8
qb_	ARPA@56 · logstd 초기 −2.0 · LR 감쇠	20.6	42.2	56.0	+13.8	43.4
qa_	ARPA@300 · 토글 없음	48.7	36.3	54.8	+18.5	35.3

- 평균 행동 도착은 세 trunk 가 54.6–56.0 % 로 붙어 있음. 표본 행동은 28.8–42.2 % 로 벌어짐
- σ 침로: n_ 50.3° · qa_ 48.7° 는 비슷하고 qb_ 20.6° 만 작음(logstd 초기 −2.0). 격차는 n_ +25.8 · qa_ +18.5 · qb_ +13.8 pt — σ 가 작은 qb_ 가 가장 작으나 0 은 아님. 세 trunk 는 보는 거리 · 토글이 같이 달라서 σ 하나의 효과로 못 읽음
- qa_ 평균 행동: 55.7 → 71.0 → 60.4 → 55.3 → 54.8 % (2 · 4 · 6 · 8 · 9.04397M) — 4M 최고 뒤 내려옴. 10-13 단계 1 의 B 확정 기준(도착 ≥ 50)은 학습 창 값 기준이라 이 숫자로 바꾸지 않음

(c) qb_ off · comm 순서가 평가 방식 · 추정량에 따라 바뀌는지

추정량	행동	off 도착 %	comm 도착 %	위 (comm − off)
끝점 16M(= 끝 모델)	표본	35.7	29.6	**off** (−6.1)
끝점 16M(= 끝 모델)	평균	53.5	53.1	**off** (−0.4)
K 점 평균(10 · 12 · 14 · 16M)	표본	25.8	33.7	**comm** (+7.9)
K 점 평균(10 · 12 · 14 · 16M)	평균	42.5	55.7	**comm** (+13.3)
확인용: K 평균에서 14M 뺌	표본	32.2	34.2	**comm** (+2.0)
확인용: K 평균에서 14M 뺌	평균	55.4	55.2	**off** (−0.2)
체크포인트별 승패(4개)	표본	comm 위 2 · off 위 2		
체크포인트별 승패(4개)	평균	comm 위 2 · off 위 2		

- 바뀜. 끝점은 off 위(평균 행동 차 −0.4 pt 로 거의 같음), K 점 평균은 comm 위. 체크포인트별로는 표본 · 평균 모두 comm 2 · off 2
- K 점 평균의 comm 우세는 off 14M 하나에서 나옴: off 14M 은 표본 6.3 % · 평균 3.7 %(배 충돌 88.6 %) — **평균 행동도 무너짐 → 그 시점 정책 자체 문제**(잡음 탓 아님), 16M 에서 회복. 14M 을 빼면(확인용, 판정 아님) 평균 행동 off 55.4 · comm 55.2 %
- off · comm 의 σ 침로는 분기 뒤 거의 같게 움직임(16M off 21.4° · comm 22.0°) → 두 팔의 잡음 크기 차로는 순서를 설명 못 함

4. 경과 · 실행 기록

- 클론 C:₩work₩DT_Vessel_v3, 브랜치 feat/fig1-latent 071487b (git pull 로 b6a4341 → 071487b fast-forward). 스펙 docs/superpowers/specs/2026-10-26-ref-port-sigma-trunk-design.md §2 (R0, 기록용 · 관문 아님)
- 명령 = 저자가 준 4줄 그대로(meaneval_ckpts.sh qb_ trunk_d6 / off / comm, VESSEL_F_ARPA_RANGE=300 qa_ trunk_d6). PYTORCH_CUDA_ALLOC_CONF 등 실행 env 추가 없음
- 시작 전 GPU(17:21): 0 = 841 MiB 2 % · 1 = 3258 MiB 12 % · 2 = 70 MiB 0 % · 3 = 2314 MiB 0 %. 다른 계정(HKK) python 이 돌고 있었음. 남의 프로세스는 안 건드림
- 시작: qb_ trunk 17:21:59. qb_ off · comm 17:22:29 · qa_ trunk 17:22:30 — 세션 실수로 30초 늦음(첫 실행에서 로그 폴더 mkdir 이 백그라운드로 가서 3개가 '로그 파일 없음'으로 못 뜸 → 바로 다시 띄움). 평가 결과와 무관
- 평가 python(mltest) 우선순위 High 로 올림(15초마다 확인 루프). 결과 무관
- 평가 1개(체크포인트 1개 · 표본 또는 평균) ≈ 30–37분: 결정 5400(burn-in 2400 + 창 3000)에 ≈ 21분 + drain ≈ 10–12분 (drain 중에는 진행 줄 안 찍힘). 인자 = curve_all 과 같음(--envs 256 --eval_decisions 3000 --burnin 2400 --drain 3000 --seed 999)

- 병목 = 프로세스당 CPU 코어 1개(17:50 실측 코어 0.92–0.94개/프로세스, GPU 사용률 10–28 %). 서버 CPU 40개 100 % 사용 중 — HKK python ≈ 33개가 각 ≈ 0.83 코어
- VRAM: 평가 프로세스당 ≈ 1.1 GB. 최대 GPU 1 = 6.0 GB(추가 프로세스 포함)
- 18:21 속도용 추가 프로세스 7개(저자 승인 '진행해줘요'): r0_extra.sh = meaneval_ckpts.sh 20–47행 env 를 그대로 eval 하고 같은 명령 · 같은 파일 이름으로 지정 체크포인트만 평가. 본 스크립트는 'epReward=' 있는 파일을 건너뜀
- 끝: qb_ off 19:32:42 · qb_ comm 19:40:22 · qa_ trunk 19:44:00 · qb_ trunk 19:45:18. 표 재생성(--table) 19:46 qb_ · qa_
- ★멈춤 · ★FAIL 없음. kill · 재시도 없음
- qb_ 표본 값 = 10-13 phase1 고정 장면 곡선(curve_qb_*.txt, 같은 인자) 재사용. qa_ 표본은 새로 잼
- qb_ 갈래 16M = step16M 체크포인트 = 끝 모델과 같은 파일(10-13 확인) → 스크립트가 끝 모델 .pt 를 따로 안 셈

---

5. 한계 — 그대로 읽을 것

- 시드 1개(43) · 평가 시드 1개(999) · 체크포인트당 평가 1회 → 같은 체크포인트를 다시 잰 흔들림 크기 모름. qb_ off 14M 같은 한 점이 평균을 좌우함
- 평균 행동은 진단용 평가임. 주 평가를 평균 행동으로 바꿀지는 저자 결정(C1) — 이 보고는 둘 다 기록만 함
- 격차의 원인(침로 모드 잡음 크기 · 잡음 상관 · 정책이 잡음에 맞춰 학습됐는지)은 이 자료로 못 가름. R1 이 그걸 보는 실험임
- 세 trunk(n_ · qb_ · qa_)는 서로 둘 이상 조건이 달라 단독 비교 안 됨
- 관문 · 판정식 · 스크립트는 안 건드렸음. 속도용 추가 프로세스는 같은 명령 · 같은 인자(§4)

---

6. 저자 결정 대기

- R1(σ trunk 3팔 ra_ · rb_ · rc_, 75분 동시) 승인 여부 · 처방 성공 기준 확정(제안: 9.04M 표본 도착 ≥ 55 % 이고 격차 ≤ 10 pt)
- C1: 주 평가를 평균 행동으로 바꿀지(바꾸면 평가 프로토콜 변경 = 저자 결정)
- 결정 전까지 추가 학습 · 평가 안 돌림

자료: runs/2026-10-02_fig1/out/meaneval_qb/ · meaneval_qa/(표본 · 평균 평가 로그, logstd, _meaneval_*.md, _log.txt, _extra_log.txt) · out/diag_trunk_n/ · out/qb/curve_qb_*.txt · out/r0_notes/(runnote.txt · r0_extra.sh · r0_logs/) · 서버 Python/_repro_out_qb/meaneval · _repro_out_qa/meaneval · 생성 report/make_report_r0.py