미리 피하는 보상 A-Z (2026-10-28, 설계 분석 · 학습 없음)

- 전제(저자 10-28 승인): 위험 비용(충돌코스 #6·per-pair #7) = 56 m(두 팔 동일) · 역할 판정기 v2 = 300 m 유지
- 근거 코드 = `feat/fig1-latent` 071487b `Python/vessel_gym.py` `_reward`(:1531-1790)·`_pairwise`(:1405-1462) · 스펙 2026-09-30 §3(판정기 v2·기각 목록)

0. 결론

- 미리 피한 배에게 '상'을 직접 주지 않음. 대신 **'곧 받을 벌을 미리 보여 주는' 위험 예고 보상(PBRS, 퍼텐셜 기반 보상 변형)** 을 0-300 m 하나의 연속 함수로 새로 둠
- 이유: 최적 행동을 바꾸지 않음(Ng 1999) → 통신을 이기게 만드는 조작이 아님 · 쌓아 먹기·우회·시간초과 유인 없음 · 미리 피한 효과가 즉시 신호로 옴(학습 연결 문제 해결)
- 기존 원거리 PBRS(#8 `farfield_coef`)는 56 m 경계에서 끊겨 '가까이 들어오면 상'이 생기는 결함 → 그대로 쓰지 않음

1. 왜 지금은 미리 안 피하나 (시간 척도)

항목	값	출처
OFF 가 정면 상대를 발견하는 시점	tcpa ≈ 18 s(56 m, 접근 ≈ 3.1 m/s)	스펙 09-30 §3-9
COLREGs 조기 행동 시점(Rule 16, imo)	tcpa 48.8 s	`EARLY_ACTION_TIME`
Rule 17(b)	15.9 s	`RULE_17B_TIME`
통신 배가 상대를 아는 시점	300 m ≈ tcpa 95 s 안팎	300 / 3.1
학습이 행동↔결과를 잇는 길이	GAE 1/(1−γλ) = 16.8 결정 ≈ 7 s · γ 지평 ≈ 40 s	γ 0.99 · λ 0.95 · 결정 0.4 s

- OFF 는 물리적으로 '조기 행동'을 못 함(발견 때 이미 48.8 s 를 지남) → 미리 피하기는 통신 배만 가능 = 정보의 가치
- 통신 배가 tcpa 60-90 s 에 조금 돌면 그 이득(56 m 비용·근접·충돌·판정 −20 회피)은 40-70 s 뒤에 옴 → 7 s 창으로는 연결 못 함 → 이득이 있어도 못 배움

2. 지켜야 할 조건

1. 두 팔 같은 보상 함수(목표 b, anti-rigging 2)
2. OFF 학습을 망치지 않음(OFF 가 못 보는 큰 항은 잡음 — n_ 직진 표류)
3. 쌓아 먹기(farming) 불가 · 우회·시간초과 유인 없음(qa_ 우회형)
4. 평가 지표를 그대로 상으로 주지 않음(Woerner 지연 점수 = 시험 문제)
5. 크기·형태는 결과 보기 전에 고정

3. 후보 7개

#	후보	내용	판정	이유
A	아무것도 안 함	56 m 비용 + 판정 300 m 만	기준선	이득은 있으나 40-70 s 뒤라 학습이 못 이음 → 통신 효과 작게 나올 위험
B	300 m 직접 비용(지금)	매 결정 위험 벌점	기각	n_ 직진형 · qa_ 우회형(보상↑·도착↓) 둘 다 만듦(R0)
C	조기 행동 보너스	일찍 우현 변침하면 +	기각(09-30)	통신만 딸 수 있는 양의 항 · 쌓아 먹기 · 시험 문제를 상으로 줌
D	늦은 행동 벌점(Rule 16 기한)	17(b) 까지 10° 못 돌면 −	기각(09-30)	OFF 는 물리적으로 못 지킴 → OFF 학습 망침·조작 소지

#	후보	내용	판정	이유
E	선회량 비용	큰 변침에 –	보류	연료 타각항·smoothness 항과 중복, 09-30 이상 행동
F	기존 원거리 PBRS(#8)	56-300 m 띠 위험 변화량	결함	56 m 안으로 들어오면 띠에서 빠져 Φ 가 0 → 접근 순간 + 보상. 끝·충돌 처리도 없음
G	**연속 위험 예고 PBRS(신규)**	Φ = –c·Σ_j g(dcpa_j)·h(tcpa_j), 0-300 m 접근 쌍, F = γΦ′ – Φ	**추천**	최적 행동 불변 · 조우 하나의 합 ≈ 0(쌓아 먹기·우회 이득 없음) · 미리 돈 순간 Φ 가 올라가 즉시 +

4. G 설계 세부 (제안 — 숫자는 결과 전 고정)

- g(dcpa) = clamp((48 – dcpa)/24, 0, 1) — 보상 위험 비용과 같은 DCPA 게이트(48 m)
- h(tcpa) = 접근 중(tcpa ≥ 0)일 때 1 – clamp(tcpa/T, 0, 1), T = 300 m 도달 시간 상한(예: 120 s). 멀수록 작게
- 56 m 경계에서 끊기지 않음(sit 곱·띠 경계 없음) · 상대가 지나가면(tcpa < 0) 0 으로 부드럽게
- F = γΦ(s′) – Φ(s), γ = 0.99(학습기와 같음) · 끝난 배(충돌·도착·시간초과)·재출현 첫 결정은 F = 0(충돌 순간 '+|Φ|' 막음)
- c: 위험한 조우 하나를 그냥 지나갈 때 56 m 안에서 받는 비용 합과 같은 크기 → 이미 있는 평가 로그에서 측정해 정하고 고정
- 토글 기본 0(비트동일), 스냅샷 키 추가, 순위 관문 v5 에 같이 넣어 '잘 피하는 배가 더 높은 점수' 확인
- 위험
  - OFF 는 Φ 의 원인(56 m 밖)을 못 봄 → 조우마다 합 0 이지만 잡음 → OFF 학습이 느려질 수 있음 → **PBRS 있/없 OFF trunk 비교로 확인**(OFF 가 나빠지면 통신 이득을 주장 못 함)
  - 다중 에이전트·부분 관측에서는 '최적 행동 불변' 보장이 약해짐 → 결과로 확인
  - 기존 earlyAvoid(9-b, 56 m 안 DCPA 증가에만 +)는 지그재그로 쌓아 먹을 여지 → 크기는 작음(조우당 +3~6), 보고만

5. 보상 말고 같이 필요한 것

- 측정(상 아님): 첫 변침 시점(tcpa·거리) · 최소 통과 거리 · 변침 크기·횟수 · 궤적 매끄러움 · Woerner(지연 포함) · 시간초과
- 판정기 v2 300 m 유지(벌점만, 쌍당 1회 –20) = 역할을 지키는지
- (선택) 관측에 쌍별 DCPA·TCPA(P15) · 증분형 침로(P14) — 미리 조금 꺾기를 행동으로 쉽게 만듦

6. 순서 (시간 고려)

1. 지금: qd_ trunk 1개(56 m + 떨림 수정, PBRS 없음) — OFF 가 배우는지
2. qd_ 가 도는 동안 G 구현·검사(Mac, 기본 비트동일)
3. qd_ 성공 시 병렬: qd_ 갈래 off·comm + qe_(= qd_ + G) trunk·갈래 → G 가 OFF 를 해치지 않으면 Fig1 은 qe_