묘책 — 2단계 학습으로 가장 안전하게, 저자 논리대로 (2026-10-30, 제안 · 저자 결정 대기)

- 앞 설계안(a3b4f2c, R* 를 처음부터)의 약점 두 개를 없앰: ① 새 trunk 를 처음부터 학습하는 위험 ② 이미 얻은 시드 2개 결과를 버림
- 근거 코드 확인: 갈래 시점 보상 변경은 학습기 재개 검사(`vessel_gym_train.py` :781 `_bad_sim`)가 막음 → 허용 키 지정으로 열 수 있음. 분기 검사(`check_branch.py` :138)는 같은 trunk 의 갈래끼리 sim 이 같은지만 봄. 원거리 COLREGs 벌점과 판정기 동시 사용은 assert(`config.py` :545)·`_reward` :1707 이 막음 → 벌점만 쓰는 경우 허용하도록 작은 수정

0. 묘책 한 줄

- **1단계 = 이미 검증된 OFF trunk(qd_ 보상, 시드 43·44 처방 기준 3/3) 를 그대로 재사용 → 2단계 = 두 팔 모두 '원거리 COLREGs 규칙 벌점(300 m)' 을 켠 같은 보상으로 OFF·통신 갈래**
- 이미 돌린 갈래(벌점 없음)는 버리지 않고 **비교 축**으로 씀 → {OFF, 통신} × {원거리 규칙 벌점 없음, 있음} 2×2

1. 왜 가장 안전한가

1. 가장 위험한 부분(OFF 가 처음부터 배우기)을 다시 안 함 — 이미 성공한 trunk(시드 43·44)를 그대로 씀. 새 시드(45-47) trunk 도 검증된 qd_ 방법 그대로
2. 2단계에서 더하는 건 '하면 안 되는 행동'(양보·정면 배 좌현, 유지 배 침로 변경)의 벌점뿐 → 이미 피할 줄 아는 배가 방향만 고치면 됨. 처음부터 배우는 것보다 훨씬 쉬움
3. 버리는 계산이 없음 — 2단계가 잘 안 되면 같은 trunk 로 대안 A(벌점 없는 갈래, 이미 2 시드 있음)를 그대로 이어감
4. 짧음 — 시드 43·44 는 trunk 가 있어 2단계 갈래만(약 3.5 h). 새 시드 trunk 와 동시에 돌림
5. 공정성 유지 — 각 단계에서 두 팔 보상 완전히 같음. 같은 trunk 짝. 메시지 입력만 다름

2. 왜 저자 논리대로인가

목표	2단계가 주는 것
a) COLREGs	300 m 안 조우 전체에서 규칙 방향이 보상됨 → 멀리 보는 통신 배만 '일찍 우현'으로 지킬 수 있음 (지금 엇갈림의 원인 = 56-300 m 좌현이 공짜였던 것)
b) DCPA 넓음	거리 관련 보상은 두 팔 같음(56 m 위험 비용 그대로)
c) 매끄러움	이미 2/2 시드에서 나옴. 규칙 벌점은 '작게 일찍 우현'을 막지 않음
d) 학습	흉내 없음, 순수 PPO 두 단계
곡선 우상향	모든 체크포인트(trunk·갈래)를 **2단계 보상으로 같은 장면 평가** → x 축 전체가 같은 보상 정의. 갈래에서 규칙을 배우며 오름

3. 논문 서술 (리뷰어가 자연스럽게 받아들이는 형태)

- "**커리큘럼**: 1단계에서 통신 없이 항해·근거리 충돌회피를 배우고(공유 사전학습), 2단계에서 COLREGs 규칙을 조우 범위 전체로 넓혀 통신 유무만 다르게 이어 학습"
- 왜 처음부터 안 하나 → 근거 있음: 관측 못 하는 거리의 보상 항을 처음부터 넣으면 학습이 무너짐(n_ 300 m 위험 비용 27.3 %, qe_ 예고 보상 0/3)
- 2×2 결과가 보여 줄 이야기(가설): "통신은 보상이 요구하는 것을 더 잘하게 해 줌 — 규칙 벌점이 없으면 효율적인(좌현 포함) 회피, 있으면 일찍 우현의 규칙 회피." 통신이 정보 증폭기라는 깔끔한 메시지

4. 동시에 돌리는 배치 (GPU 4장, 결과에 따라 갈림)

GPU	무엇	시간
0	시드 43 2단계 갈래 OFF·통신(qd_ trunk 재사용)	약 3.5 h
1	시드 44 2단계 갈래 OFF·통신(qd2_ trunk 재사용)	약 3.5 h
2	시드 45 trunk(qd_ 방법 그대로)	약 2.5 h
3	시드 46 trunk → 이어서 시드 47 trunk	약 5 h

- 2단계 결과(43·44) 가 사전 기준을 넘으면 → 45-47 도 2단계 갈래 → 5 시드
- 못 넘으면 → 45-47 은 벌점 없는 갈래(대안 A) → 5 시드, COLREGs 는 '나빠지지 않음'으로 보고
- 어느 쪽이든 trunk 3개는 그대로 쓰임

5. 사전 기준(결과 전에 고정, 제안)

- 2단계 안전: OFF 2단계 갈래 16M 평균 행동 도착 ≥ 같은 시드 trunk 9.04M − 5 pt (규칙 벌점이 OFF 를 망치지 않음)
- Fig1 판정(5 시드 모이면): 시드별 짝 차이 평균 ± 95 % CI + 승 수, 성공 = 승 ≥ 4/5 이고 CI 가 0 을 안 걸침. 주 지표 = 충돌 · 도착 · DCPA · Woerner · 방향 변화
- 주 평가 = 평균 행동, 표본 행동 부록
- 이른 행동 지표(보상 안 함): 조우별 첫 우현 ≥ 10° 변침 때 거리·tcpa, 56 m 밖에서 풀린 조우 비율

6. 필요한 코드 (작음, 기본값 비트동일)

1. 원거리 COLREGs 벌점(`COLREGS_FAR_RANGE=300`, `FAR_MODE=penalty`)을 판정기 v2 와 같이 쓸 수 있게(벌점만, 가산 없음 확인)
2. 갈래 시점 보상 변경 허용: 허용 키(원거리 벌점 2개)만, 분기점(`resume_at == comm_on_at`)에서만, 스냅샷에 기록 → 그 뒤 재개는 다시 엄격
3. runner: trunk 재사용(시드별 원 접두어) · 2단계 env 를 갈래·평가에만 · 곡선은 모든 체크포인트를 2단계 보상으로 평가
4. 평가 스크립트(평균 행동·절제)에 2단계 env 전달 · 이른 행동 지표(평가 전용, 다음 날 가능)
5. 검사: 골든 비트동일 · 보상 경로 단위 검사 · 재개 거부/허용 검사 → Mac 반나절

7. 위험

- 2단계에서 OFF 가 규칙 벌점 때문에 지나치게 소극적이 될 수 있음 → §5 안전 기준으로 확인
- 통신의 COLREGs 개선은 보장 못 함 → 고정 기준대로 보고. 안 되면 대안 A 결과로 정직하게

8. MoE (10-30 추가, 저자 질문)

- 현 구조: 상황별 전문가 5개, 라우팅 키 = 자기 레이더(56 m) 기준 COLREGs 상황 → 두 팔 같은 구조(공정)
- 주 평가 결정 몫(시드 43): 조우 전문가 4개 = OFF 12.3 % · 통신 10.7 %. 정면 전문가 결정 수 149,270 → 55,115(−63 %). 나머지는 '조우 없음' 전문가
- 뜻: 56 m 밖(레이더 밖) 행동은 전부 '조우 없음' 전문가가 맡음 → 2단계 원거리 규칙 벌점(sit = 0 일 때만)도 이 전문가가 배움. 통신 배는 메시지로 상대 역할을 알아 이 전문가 안에서 '일찍 우현'을 배울 수 있음, OFF 는 일반적인 우현 선호만 배울 수 있음
- 결정: **MoE 구조는 바꾸지 않음** — 바꾸면 trunk 재사용·공정성(두 팔 같은 구조)·지금까지 결과가 깨짐. 통신 팔만 원거리 상황으로 라우팅하는 것도 구조가 달라져 불공정 → 하지 않음
- 논문용 추가(평가만): ① 팔별 전문가 사용 몫 ② 첫 우현 변침이 어느 전문가에서 일어났는지(통신 = 레이더 접촉 전 '조우 없음' 전문가 → 이른 행동의 직접 증거) ③ 시간 되면 부록: 단일망(USE_MOE=0) 1-2 시드를 같은 2단계 방식으로 → '통신 이득이 MoE 탓이 아님'

- 위험: 56 m 에서 전문가가 바뀌는 순간 행동이 끊길 수 있음 · 조우 전문가 데이터가 적음(약 11 %) — 두 팔 같음, 매끄러움 지표로 확인